

# Metody Obliczeniowe w Nauce i Technice

## Laboratorium 8

### Page Rank

#### Wprowadzenie

Algorytm Page Rank, zaproponowany przez S. Brina i L. Page'a w 1998 roku [1], ocenia istotność wierzchołków grafu skierowanego na podstawie iteracyjnego modelu błędzenia przypadkowego (*random surfer*). Wartość Page Rank wierzchołka odpowiada stacjonarnemu rozkładowi prawdopodobieństwa odwiedzenia tego wierzchołka przez nieskończenie długi spacer losowy z teleportacją.

#### Literatura

- S. Brin, L. Page (1998). The PageRank Citation Ranking
- Stanford Network Analysis Project (SNAP) Datasets
- T. Haveliwalla, S. Kamvar (2003). *The Second Eigenvalue of the Google Matrix*. Stanford Tech. Report.

#### Notacja

Niech  $G = (V, E)$  będzie grafem skierowanym,  $n = |V|$ .

- $B_u = \{v \in V : (v, u) \in E\}$ , zbiór poprzedników wierzchołka  $u$ ,
- $F_v = \{u \in V : (v, u) \in E\}$ , zbiór następników wierzchołka  $v$ ,
- $N_v = |F_v|$ , stopień wyjściowy wierzchołka  $v$ ,
- wierzchołek  $v$  nazywamy *wiszącym* (*dangling*), jeśli  $N_v = 0$ .

#### Zadanie 1: Prosty ranking wierzchołków

Zaimplementuj prosty model błędzenia przypadkowego po grafie skierowanym. Ranking  $r(u)$  wierzchołka  $u$  definiujemy rekurencyjnie:

$$r(u) = d \sum_{v \in B_u} \frac{r(v)}{N_v}, \quad (1)$$

gdzie  $d \in (0, 1]$  jest parametrem tłumienia (*damping factor*). W zapisie macierzowym:

$$\mathbf{r} = d \mathbf{A} \mathbf{r}, \quad (2)$$

gdzie  $\mathbf{A}$  jest **kolumnowo-stochastyczną** macierzą przejścia:

$$A_{u,v} = \begin{cases} \frac{1}{N_v} & \text{jeśli } (v, u) \in E, \\ 0 & \text{w przeciwnym wypadku.} \end{cases} \quad (3)$$

**Uwaga o konwencji.** Kolumna  $v$  macierzy  $\mathbf{A}$  koduje rozkład prawdopodobieństwa kroku ze wierzchołka  $v$  do jego następników. Dlatego  $\sum_u A_{u,v} = 1$  dla każdego wierzchołka niewiszącego  $v$ . Łatwo sprawdzić, że tak zdefiniowana macierz spełnia równanie skalarnie (1):

$$(\mathbf{A}\mathbf{r})_u = \sum_{v \in V} A_{u,v} r(v) = \sum_{v \in B_u} \frac{r(v)}{N_v}.$$

Konwencja przeciwna ( $A_{u,v} = 1/N_u$  dla krawędzi  $(u, v)$ ) wymagałaby równania  $\mathbf{r} = d \mathbf{A}^\top \mathbf{r}$ , co jest źródłem częstej pomyłki w literaturze.

**Wymagania.**

1. Zaimplementuj funkcję budującą macierz  $\mathbf{A}$  na podstawie reprezentacji grafu (lista sąsiedztwa lub macierz rzadka).
2. Zaimplementuj metodę potęgową obliczającą dominujący wektor własny  $\mathbf{q}_1$  macierzy  $d\mathbf{A}$  znormalizowany normą  $L_1$ .
3. Zweryfikuj poprawność, porównując wynik z pełną dekompozycją widmową (np. `numpy.linalg.eig`).
4. Przetestuj implementację na co najmniej trzech **silnie spójnych** grafach skierowanych o liczbie wierzchołków  $|V| > 10$ , różniących się strukturą (na przykład cykl ze strunami, graf Erdős–Rényi, graf typu *scale-free*).

## Zadanie 2: Page Rank z teleportacją

Rozszerz model z Zadania 1, dodając możliwość skoku do losowego wierzchołka grafu:

$$r(u) = d \sum_{v \in B_u} \frac{r(v)}{N_v} + (1-d) e(u), \quad (4)$$

gdzie  $\mathbf{e}$  jest *wektorem preferencji teleportacji*, takim że  $\|\mathbf{e}\|_1 = 1$  oraz  $e_i \geq 0$  dla wszystkich  $i$ . W zapisie macierzowym:

$$\mathbf{r} = \mathbf{B} \mathbf{r}, \quad \mathbf{B} = d\mathbf{A} + (1-d) \mathbf{e} \mathbf{1}^\top, \quad (5)$$

przy warunku normalizacji  $\|\mathbf{r}\|_1 = 1$ . Macierz  $\mathbf{B}$  jest kolumnowo-stochastyczna i ściśle dodatnia (po uwzględnieniu wierzchołków wiszących, patrz niżej), więc na mocy twierdzenia Perrona–Frobeniusa istnieje jednoznaczny dominujący wektor własny odpowiadający wartości  $\lambda_1 = 1$ .

### Obsługa wierzchołków wiszących

Dla wierzchołka wiszącego  $v$  kolumna  $v$  macierzy  $\mathbf{A}$  jest zerowa, więc  $\|\mathbf{A}\mathbf{r}\|_1$  jest *mniejsza* niż  $\|\mathbf{r}\|_1$ . Aby zachować stochastyczność, zastępujemy zerowe kolumny wektorem teleportacji  $\mathbf{e}$ . Definiując wskaźnik wiszących  $\mathbf{c} \in \{0, 1\}^n$ , formalnie:

$$\hat{\mathbf{A}} = \mathbf{A} + \mathbf{e} \mathbf{c}^\top.$$

Macierz  $\hat{\mathbf{A}}$  jest kolumnowo-stochastyczna, a Page Rank jest dominującym wektorem własnym macierzy  $\mathbf{B} = d\hat{\mathbf{A}} + (1-d) \mathbf{e} \mathbf{1}^\top$ .

## Algorytm metody potęgowej

Bezpośrednie budowanie macierzy  $B$  wymaga  $O(n^2)$  pamięci, co jest niepraktyczne dla grafów rzędu  $10^6$  wierzchołków. Sprytna implementacja [1] wykorzystuje tożsamość, w której tracona masa jest jawnie redystrybuowana przez wektor  $e$ . Algorytm 1 przedstawia procedurę.

---

**Algorithm 1** Page Rank metodą potęgową z redystrybucją masy

---

**Require:** macierz  $A$  (rzadka), wektor  $e$ , parametr  $d$ , próg  $\varepsilon$

```
1:  $r_0 \leftarrow e$ 
2:  $i \leftarrow 0$ 
3: repeat
4:    $r_{i+1} \leftarrow d A r_i$                                  $\triangleright$  krok podstawowy; masa się nie zachowuje
5:    $\rho \leftarrow \|r_i\|_1 - \|r_{i+1}\|_1$                      $\triangleright$  utracona masa: tłumienie + wiszące
6:    $r_{i+1} \leftarrow r_{i+1} + \rho e$                          $\triangleright$  redystrybucja przez wektor preferencji
7:    $\delta \leftarrow \|r_{i+1} - r_i\|_1$ 
8:    $i \leftarrow i + 1$ 
9: until  $\delta < \varepsilon$ 
10: return  $r_i$ 
```

---

## Wymagania

1. Zaimplementuj algorytm 1 oraz wariant referencyjny oparty na jawnym konstruowaniu macierzy  $B$  (do weryfikacji krzyżowej).
2. Sprawdź zgodność wyniku z funkcją `networkx.pagerank` (lub równoważną).
3. Przetestuj algorytm na wybranym zbiorze z bazy SNAP (np. `wiki-Vote`, `web-Stanford`). W razie braku dostępu sieciowego użyj grafu syntetycznego o rozkładzie stopni *power-law* (np. `networkx.scale_free_graph`).
4. Zbadaj wpływ parametru tłumienia:  $d \in \{0.5, 0.6, 0.75, 0.85, 0.9\}$ .
5. Zbadaj wpływ wektora preferencji  $e$ : porównaj wariant jednorodny  $e = \frac{1}{n}\mathbf{1}$  z wariantami spersonalizowanymi (np. teleportacja skupiona na wybranych wierzchołkach).

## Sugerowane wizualizacje

- Rysunek grafu z rozmiarem (lub kolorem) wierzchołka proporcjonalnym do wartości Page Rank.
- Krzywa zbieżności  $\delta_i = \|r_{i+1} - r_i\|_1$  w skali półlogarytmicznej; teoretyczne nachylenie wynosi  $\log d$ .
- Histogram (w skali logarytmicznej) wartości Page Rank, ujawniający ciężki ogon rozkładu.
- Wykres rozrzutu Page Rank w funkcji stopnia wejściowego  $|B_u|$  (skala  $\log\text{--}\log$ ).
- Wykres słupkowy top- $k$  wierzchołków w funkcji parametru  $d$ , pokazujący wrażliwość rankingu.

## Kryteria oceny

- Poprawność implementacji (zgodność z referencją, normalizacja, obsługa wierzchołków wiszących).
- Jakość weryfikacji (testy na grafach różnej topologii, porównanie z bibliotekami referencyjnymi).

- Analiza wpływu parametrów ( $d$ ,  $e$ ) oraz rozważania nad konwergencją.
- Czytelność kodu i jakość wizualizacji.

## Literatura

- [1] S. Brin, L. Page (1998). *The Anatomy of a Large-Scale Hypertextual Web Search Engine*. Stanford InfoLab Technical Report.